





各 Task 的代表性能力结果

各面板使用不同指标和测试设置，柱高仅表示对应面板内的结果。



Task 3 使用 100-world 配对主测试; Task 4 的 Die Hardest 来源 checkpoint 数值来自另一套历史 1,000-world 基准测试。