

Task 4 得分、安全与推理延迟

散点比较专项模型的 Task 4 得分与完整动作 P95 延迟。

图中专项实验均记录 0 自杀；安全轨迹在 step 77 复现反例 27155。

